

# Modelagem Preditiva de Desempenho no Moodle Utilizando Variáveis Comportamentais e xAPI

1

**Abstract.** *Engagement and performance analysis in Virtual Learning Environments (VLEs) is fundamental to support pedagogical decisions. Traditional aggregated data often fail to capture students' behavioral nuances. This paper investigates the use of complex and temporal predictive variables, extracted under the semantics of the xAPI specification, to improve the prediction of academic success. For this purpose, a public Moodle dataset was processed, cleaned, and integrated to generate behavioral metrics. Subsequently, machine learning algorithms were trained to classify student performance and identify dropout risk profiles. The findings indicate that including these new variables increases the predictive accuracy of the models compared to relying exclusively on basic aggregated data. We conclude that the proposed method provides accurate analytical tools for teachers, enabling early interventions and personalized teaching strategies.*

**Keywords:** *Data Science. Learning Analytics. Machine Learning. xAPI. Academic Performance.*

**Resumo.** *A análise de engajamento e desempenho em Ambientes Virtuais de Aprendizagem (AVA) é fundamental para apoiar decisões pedagógicas. Dados agregados tradicionais frequentemente falham ao não capturar as nuances comportamentais dos estudantes. Este artigo investiga o uso de variáveis preditivas complexas e temporais, extraídas sob a semântica da especificação xAPI, para aprimorar a previsão do sucesso acadêmico. Para isso, um conjunto de dados público do Moodle foi processado, limpo e integrado, gerando métricas comportamentais. Em seguida, algoritmos de machine learning foram treinados para classificar o desempenho dos alunos e identificar perfis com risco de evasão. Os resultados indicam que a inclusão dessas novas variáveis aumenta a precisão preditiva dos modelos em comparação ao uso exclusivo de dados básicos. Conclui-se que o método proposto fornece ferramentas analíticas precisas para os professores, o que viabiliza intervenções precoces e estratégias de ensino personalizadas.*

**Palavras-chaves:** *Ciência de Dados. Learning Analytics. Machine Learning. xAPI. Desempenho Acadêmico.*

## 1. Introdução

A expansão de Ambientes Virtuais de Aprendizagem (AVA), como o *Moodle*, exige abordagens avançadas para avaliar o desempenho e o engajamento dos alunos. Sistemas de registro tradicionais fornecem dados agregados que frequentemente não capturam as nuances comportamentais dos estudantes.

Este trabalho integra técnicas de *Learning Analytics* e Ciência de Dados para investigar se a extração de variáveis comportamentais complexas e temporais melhora a precisão na predição do sucesso acadêmico.

Para estruturar os dados, utiliza-se a especificação *xAPI* (*Experience API*). Esse padrão técnico rastreia e registra experiências de aprendizagem, o que facilita a comparação de resultados de forma independente da plataforma. Os registros são armazenados em um *Learning Record Store* (LRS). No contexto do *Moodle*, eventos de *log* convencionais são convertidos em declarações *xAPI* padronizadas. Esse processo viabiliza a construção de conjuntos de dados adequados para análises preditivas.

Para construir as variáveis do modelo, este estudo extrai métricas propostas por Leitão (2017) e por Li et al. (2021). O primeiro grupo foca na performance em questionários e inclui variáveis como Pontuação, Nível de Confusão, Tempo de Resposta e Nível de Desordem. O segundo grupo quantifica a interação do estudante com o ambiente, incluindo Visualizações por Objeto de Conteúdo, Tempo Total Gasto em Visitas Reais, Porcentagem do Curso Acessado e Tentativas por Questionário.

Neste artigo, essas variáveis alimentam algoritmos de *machine learning* para classificar o desempenho acadêmico e detectar alunos em risco de evasão ou reprovação. O objetivo é avaliar de forma empírica se as variáveis de engajamento baseadas em *xAPI* aumentam o poder preditivo dos modelos em comparação ao uso isolado de dados brutos. Essa abordagem fornece ferramentas analíticas precisas para apoiar diagnósticos e embasar intervenções pedagógicas.

## 2. Trabalhos Relacionados

Para avaliar o desempenho do aluno e o impacto das atividades pedagógicas, é possível extrair dados valiosos diretamente dos Ambientes Virtuais de Aprendizagem (AVAs) por meio da utilização de diversas métricas. Essas métricas oferecem *insights* sobre a interação do estudante com o material didático e seu desempenho em atividades avaliativas, permitindo aos professores uma compreensão mais aprofundada do processo de aprendizagem, facilitando a identificação de diferentes perfis cognitivos.

### 2.1. Métricas Propostas por Leitão

Leitão (2017), baseando-se nos trabalhos de Biswas e Ghosh (2007), propôs a adoção de um conjunto de cinco métricas para avaliar o impacto de uma aula e o desempenho do estudante em questionários avaliativos dentro do AVA.

1. **Métrica de Pontuação:** Esta é uma medida clássica que calcula a média obtida por um estudante em atividades avaliativas, sendo determinada como o produto do valor de cada questão pelo total de respostas corretas (TRC). Essa métrica oferece uma visão geral do desempenho do estudante em termos de respostas corretas. Pode ser expressa pela Equação 1 (LEITÃO, 2017, p.34):

$$Pts = \left( \frac{10}{\text{TotaldeQuestões}} \right) \times TRC$$

2. **Métrica de Nível de Confusão:** Esta métrica é utilizada para medir o nível de incerteza (ou dúvida) de um estudante ao responder uma questão. Tal incerteza

é inferida a partir da quantidade de vezes que uma alternativa diferente da atual foi marcada, de modo que, quanto mais vezes a resposta da questão tiver sido trocada, maior a incerteza demonstrada pelo aluno (LEITÃO, 2017, p.34). Um tempo excessivamente longo e múltiplas trocas de resposta podem indicar dificuldade na compreensão do conteúdo abordado.

3. **Tempo de Resposta:** Esta métrica calcula o tempo que um estudante precisou para resolver cada questão ou um conjunto de questões. A quantidade de tempo gasto pode indicar que o estudante não compreendeu bem o assunto avaliado, que a questão contém um nível de dificuldade muito elevado ou que precisaria ser reformulada (LEITÃO, 2017, p.35). A análise deste dado auxilia na identificação de áreas onde o aluno necessita de mais reflexão, e o seu cruzamento com o Nível de Confusão pode revelar a necessidade de reforço em conteúdos específicos.
4. **Nível de Desordem:** Esta métrica calcula a desordem das respostas finais usando a entropia das permutações ( $H_o$ ), indicando o quanto um estudante respondeu às questões em uma ordem diferente da originalmente prevista pelo professor (LEITÃO, 2017, p.36). Quanto mais perto de '1', maior a desordem da resposta. Essa métrica pode fornecer pistas sobre a lógica de estudo do aluno, revelando nuances de estilos de aprendizagem não-lineares, e auxiliar na avaliação da necessidade de modificações na estrutura das avaliações.
5. **Métrica de Nível de Compreensão:** Esta métrica busca estimar o entendimento do aluno em relação ao conteúdo, relacionando o tempo de resposta com a complexidade intrínseca da pergunta (BISWAS; GHOSH, 2007 apud LEITÃO, 2017, p. 37). Para isso, ela considera fatores como o Índice de Dificuldade do Tópico (IDT), Índice de Dificuldade do Conceito (IDC) e Índice de Dificuldade da Questão (IDQ), o “Desvio” da resposta (proximidade da alternativa marcada em relação à resposta correta) e o tempo de resposta para o cálculo definido pela Equação 2 (LEITÃO, 2017, p.37):

$$L_u = \frac{IDT * IDC * IDQ * Desvio}{Tempo de Resposta}$$

## 2.2. Métricas de Engajamento de Aprendizagem em Cursos Online (Li et al., 2021)

Em um contexto mais amplo de ambientes de aprendizagem online e sistemas de gestão de aprendizagem (LMS), Li et al., 2021 desenvolveram um conjunto de métricas para quantificar o engajamento do aprendiz e explorar sua relação com os resultados de aprendizagem em cursos de engenharia. Essas métricas são baseadas em dados coletados diretamente do LMS (Brightspace, neste caso) e oferecem uma perspectiva valiosa sobre o comportamento do estudante.

Entre os indicadores estruturados, destacam-se as **Visualizações por Objeto de Conteúdo (VC)**, que representam o número total de visualizações de um objeto dividido pelo total de conteúdos acessados na seção, e o **Tempo Total Gasto em Visitas Reais (TT)**, correspondente ao tempo em que o conteúdo é visualizado e o usuário permanece efetivamente ativo. A mensuração abrange também a **Porcentagem do Curso Acessado (CA)**, a **Porcentagem de Feedback Lido (FR)** — que mede o interesse do aluno em sua própria evolução — e as **Tentativas por Questionário (QA)**, referentes ao esforço despendido em cada tarefa avaliativa.

Os resultados do estudo de Li et al., 2021 indicaram que essas métricas de engajamento estão positivamente correlacionadas com a nota final dos alunos, sendo preditores significativos do desempenho. Embora a relação entre engajamento e resultados de aprendizagem possa ser mais complexa do que uma simples linearidade, esses achados reforçam a importância de monitorar o comportamento dos alunos em AVAs para compreender e otimizar o processo de ensino-aprendizagem. Notavelmente, o “tempo total gasto na plataforma” foi o preditor menos significativo entre as métricas de engajamento neste estudo, o que pode ser atribuído a diferentes formas de registro de tempo pelos LMSs e ao “ruído” introduzido por janelas de navegador abertas sem atividade real.

### 2.3. Discussão e Aplicações das Métricas de Desempenho

A análise dessas métricas, em conjunto com outras informações disponíveis nos AVAs, pode fornecer aos professores *insights* valiosos sobre o processo de aprendizagem de cada aluno. Ao identificar padrões de comportamento, dificuldades específicas e preferências de estudo, os educadores podem adotar estratégias pedagógicas mais personalizadas e eficazes.

Enquanto Leitão (2017) focou na extração teórica dessas métricas e Li et al. (2021) limitaram-se a correlacioná-las com a nota, este trabalho difere ao integrar essas métricas estruturadas via xAPI como *features* ativas no treinamento de algoritmos de *machine learning* (CatBoost) para prever o risco de evasão.

## 3. Dados e definição do problema

A diversidade de plataformas educacionais causa o isolamento de dados. Embora sistemas de gestão de aprendizagem (*Learning Management Systems* ou *LMS*) como o *Moodle* capturem interações detalhadas, os registros permanecem em esquemas relacionais proprietários. Isso dificulta a interoperabilidade e a análise entre plataformas. A especificação xAPI soluciona esse problema ao organizar as ações em tuplas do tipo Sujeito-Verbo-Objeto. Contudo, muitos dados históricos de aprendizagem continuam em formatos tabulares tradicionais. Converter esses arquivos legados para o padrão xAPI é crucial para viabilizar modelos preditivos transversais em *Learning Analytics*.

Diante disso, este trabalho apresenta a seguinte pergunta de pesquisa: **a conversão de registros tabulares para a estrutura semântica xAPI permite extrair variáveis preditivas complexas e temporais, como padrões sequenciais de navegação e intervalos de latência, que elevam a precisão dos modelos de *machine learning* em comparação ao uso de dados agregados tradicionais?**

Para guiar a validação técnica do *pipeline* e do *dataset*, estabelecem-se duas hipóteses:

- **Hipótese 1:** Existe uma correlação positiva e direta entre o tempo de engajamento ativo do estudante no Ambiente Virtual de Aprendizagem (AVA) e o seu desempenho acadêmico.
- **Hipótese 2:** O percentual de curso acessado pelo aluno apresenta a correlação positiva mais forte com o desempenho acadêmico final entre todas as variáveis extraídas do ambiente virtual.

A investigação utiliza o conjunto de dados público e anonimizado *Learn Moodle*, fornecido pela Moodle Pty Ltd (2016) para fins científicos.

Esse *dataset* contém as interações de 2.167 usuários matriculados na edição de agosto de 2016 do curso aberto e *online* “Teaching with Moodle”. O curso durou quatro semanas e os dados brutos estão divididos em seis arquivos estruturados no formato CSV. O arquivo principal de auditoria é o `<mdl_logstore_standard_log.csv>`, que registra cada ação executada no sistema de forma granular. Os atributos incluem identificadores do evento, contexto da ação, nível do contexto, marcas temporais no padrão *Unix* (*timecreated*), endereço *IP* mascarado e origem da requisição, como interfaces *web* ou serviços de rede. O segundo arquivo crítico é o `<mdl_course_modules_completion.csv>`, que documenta o estado de conclusão das atividades de cada estudante.

#### 4. Metodologia

Atualmente, o acesso de professores e pesquisadores aos dados de interação em ambientes como o Moodle ocorre principalmente através de relatórios estáticos e extrações de tabelas de *log* do sistema de banco de dados. Como observado no *dataset* público Moodle Pty Ltd (2016), os registros de aprendizagem são armazenados de forma fragmentada em múltiplos arquivos. A estrutura inclui históricos de notas (`<mdl_grade_grades_history>`), conclusões de módulos (`<mdl_course_modules_completion>`) e *logs* de eventos padrão (`<mdl_logstore_standard_log>`).

Para a divulgação, o conjunto de dados foi anonimizado. O *username* foi convertido na chave relacional entre as tabelas e na principal forma de identificação do discente. Por conterem informações residuais (como idioma, cidade e país), as tabelas `<mdl_user>` e `<mdl_badge_issued>` não foram utilizadas, pois seu conjunto de dados é irrelevante para a construção das declarações xAPI. Em contrapartida, o arquivo `<mdl_course_modules>` forneceu a composição de cada módulo, permitindo a estruturação do contexto (*contextActivities*). A geração dos *statements* exigiu o cruzamento direto dessas tabelas estruturais.

Durante a análise do *dataset*, percebeu-se que o arquivo de log `<mdl_logstore_standard_log>` contém o registro completo do Moodle, englobando interações de disciplinas alheias ao escopo deste estudo. Para garantir a precisão analítica, aplicou-se um filtro focado na disciplina avaliada, utilizando o *courseID* 10464 e o identificador 0 para preservar eventos de *login* e processos contínuos do sistema.

Identificou-se também a presença de ruídos temporais, com eventos datados de 2014, embora o curso analisado tenha ocorrido efetivamente entre agosto e setembro de 2016. A filtragem para esse período específico foi essencial, pois os dados fora dessa janela temporal afetavam drasticamente o cálculo das métricas de tempo de resposta e tempo real de interação.

Outra etapa de limpeza consistiu na remoção dos registros dos facilitadores do curso. A exclusão baseada apenas no nível de acesso (*edulevel*) mostrou-se ineficaz, pois algumas atividades concediam permissões de professor aos estudantes. Dessa forma, os dois facilitadores mencionados na documentação original foram rastreados e excluídos por meio de eventos específicos de sistema, como `<\core\event\course_module_updated>`. Com isso, preservaram-se apenas as ações dos discentes necessárias para as métricas. Além disso, os identificadores numéricos longos dos usuários foram renomeados para formatos curtos e incrementais.

Como não foi possível aplicar a extensão original para a conversão direta, desenvolveu-se um algoritmo em Python. A ferramenta utiliza a biblioteca *DuckDB* para as filtrações iniciais e o cruzamento das tabelas. Um desafio específico dessa base foi a ausência de uma chave que associasse diretamente o histórico geral de *logs* à tabela de notas. Para solucionar essa limitação, aplicou-se a técnica de *fuzzy join*, correlacionando os *timestamps* de criação da nota e de registro do evento.

Após o pré-processamento, o algoritmo executa um laço de repetição para traduzir cada linha de *log* em um *statement* xAPI, utilizando como referência o comportamento do *plugin* original (PESCE, 2026). O foco consistiu em extrair eventos vitais para as métricas, englobando as ações *viewed*, *submitted*, *completed*, *started* e *<feedback\_viewed>*. Eventos secundários foram mantidos com seus nomes originais para viabilizar o rastreamento do tempo total de permanência do aluno na plataforma.

Na lógica de conversão temporal e semântica, a conclusão de uma atividade com nota atribuída gerou o verbo *scored*. De modo análogo, os registros *<feedback\_viewed>*, *<attempt\_reviewed>*, *<grade\_viewed>* e *<report\_viewed>* foram convertidos no evento genérico de recebimento de revisão. O procedimento forneceu o *dataset* completo, traduzido para *statements* xAPI e estruturado no formato JSON para acesso público.

## 5. Configuração experimental

O problema foi inicialmente abordado como uma tarefa de regressão para prever notas em uma escala contínua de 0 a 10. Contudo, devido à complexidade e à escassez de dados, optou-se por uma modelagem de classificação. Para isso, as notas foram arredondadas e agrupadas em cinco categorias de desempenho (de 0 a 2; de 2,1 a 4; de 4,1 a 6; de 6,1 a 8 e de 8,1 a 10).

O algoritmo *Random Forest Classifier* foi utilizado na classificação. Esse modelo oferece robustez contra *overfitting* para este *dataset* e permite a extração da métrica de *feature importance*. O algoritmo *Support Vector Machine* (SVM) também foi implementado como método de teste e comparação.

O *dataset* foi dividido na proporção de 80% para treinamento e 20% para teste. O desempenho dos modelos foi avaliado pelas métricas de Acurácia, Precisão, *F1-Score* e Matriz de Confusão. Por fim, os modelos foram avaliados com e sem a inclusão das métricas educacionais extraídas, com o objetivo de quantificar o impacto exato dessas variáveis nas previsões finais.

## 6. Resultados e discussão

Uma vez concluído o pré-processamento, os algoritmos foram usados para treinar os modelos com os dados, gerando os resultados constantes na Tabela 1. Em seguida, para facilitar a comparação entre os modelos e seus respectivos métodos de imputação, geramos o gráfico comparativo, onde é possível constatar que, apesar de similares, o *Random Forest* ganhou do SVM na maioria das vezes, perdendo apenas com a imputação *median*.

A tabela 1 apresenta o desempenho de diferentes modelos, a Figura 1 apresenta o gráfico comparativo do *f1-score* entre as imputações da *Random Forest* e SVM e a Figura 2 apresenta a matriz de confusão.

Tabela 1. Tabela de Desempenho dos Modelos com Índices

|   | Modelo        | Imputação     | Acurácia | Precisão | F1-Score |
|---|---------------|---------------|----------|----------|----------|
| 6 | Random Forest | constant      | 0.756303 | 0.755612 | 0.755090 |
| 0 | Random Forest | mean          | 0.743697 | 0.740890 | 0.741727 |
| 1 | SVM           | mean          | 0.731092 | 0.729996 | 0.729995 |
| 7 | SVM           | constant      | 0.726891 | 0.728901 | 0.727630 |
| 3 | SVM           | median        | 0.718487 | 0.714589 | 0.715730 |
| 2 | Random Forest | median        | 0.722689 | 0.708413 | 0.712462 |
| 4 | Random Forest | most_frequent | 0.718487 | 0.699167 | 0.706063 |
| 5 | SVM           | most_frequent | 0.701681 | 0.701770 | 0.700658 |




Figura 1. Comparação de Performance por modelo e imputação






Figura 2. Matriz de Confusão - Random Forest (constant)

Analisando detidamente os resultados, pudemos constatar que na Matriz de Confusão da Random Forest (usando a imputação *constant*) o algoritmo é comparativamente melhor em prever os alunos que estarão nas extremidades em questão de notas, aqueles que se sairão muito bem ou muito mal, do que em prever (com acerto) aqueles que tem notas medianas. E com a própria função do *Random Forest* de calcular as *features* mais importantes, podemos ver quais métricas foram consideradas as top 15 e o grau de importância que elas alcançaram.



**Figura 3. Top 15 Features mais importantes (Random Forest)**

### 6.1. Hipótese 1: Existe uma correlação positiva e direta entre o tempo de engajamento ativo do estudante no Ambiente Virtual de Aprendizagem (AVA) e o seu desempenho acadêmico.



**Figura 4. Tempo Total de Engajamento vs Desempenho Acadêmico**

Sobre a hipótese 1, utilizando o *Spearman* chegamos à conclusão de que ela está correta e que existe correlação positiva e estatisticamente significativa do tempo total que o aluno passa no curso com a nota final dele, como podemos ver na Figura 4, que demonstra um Coeficiente de Correlação ( $\rho$ ): 0.3006 e P-value: 5.4315e-26.



Infelizmente, por conta da anonimização do *dataset*, não temos como saber os critérios avaliativos do curso em questão, então só podemos especular sobre o motivo de tantos alunos com tempo total zero no curso terem conseguido alcançar todos os tipos de notas, mas o cálculo do *Spearman* deixou claro que ainda assim há uma correlação positiva entre tempo e nota.

## 6.2. Hipótese 2: O percentual de curso acessado por aluno apresenta a correlação positiva mais forte com o desempenho acadêmico final do aluno dentre todas as variáveis extraídas do ambiente virtual.

A própria métrica do *Random Forest* já havia indicado que o percentual do curso acessado seria a métrica mais relevante para determinar a nota do aluno, e o cálculo do *Spearman* apenas comprovou isto, conforme pode ser visto na Figura 5.





Figura 5. Força de Correlação das Variáveis com o Desempenho Final

Podemos constatar que uma sessão específica do curso foi a mais relevante para a determinação da nota do aluno, seguida da métrica da porcentagem do curso inteiro que foi acessado. Como o *dataset* foi anonimizado, não conseguimos, infelizmente, determinar o motivo pelo qual essa sessão foi a mais importante, mas isso pode ser afirmado, razão pela qual comprovamos que a hipótese foi aceita.


## 7. Limitações ou ameaças à validade

Como já observado em outras pesquisas na área, como as de (ZHENG et al., 2015) e (KIZILCEC; PIECH; SCHNEIDER, 2013), nos MOOCS (*Massive Open Online Courses*), a taxa de alunos que chega a concluir o curso, ou mesmo a participar, é bem menor que o normal, e apesar dessas pesquisas tentarem entender os motivos por trás das evasões, para a nossa análise, o número massivo de alunos que não participaram do curso, mas se inscreveram, afetou drasticamente os resultados, aumentando muito a eficácia dos modelos em identificar os alunos que se sairão mal no curso, quando comparadas às versões sem evasores (na sessão 6), como pode ser visto na Figura 6.



**Figura 6. Comparação de Performance por Modelo e Imputação**

Outro desafio envolveu a métrica de Tempo Total Gasto em Visitas Reais (TT), cujo cálculo considerava o *timeout* padrão do *Moodle* (medindo o tempo até o último *statement* antes de um novo *login*). Contudo, como este curso específico não apresentava um *logout* automático por inatividade, foi necessário estipular um limite de tempo manualmente. A Figura 7 ilustra o impacto da aplicação desse *timeout* no cálculo do tempo total:



**Figura 7. Impacto do timeout no Tempo de Tela e sessões fechadas por timeout**

Após a análise dos resultados do *timeout* com os modelos de predição, optamos por limitar o tempo de sessão de cada usuário em 12h, pois a permanência acarretava no maior *f1-score* em geral, enquanto mantinha os dados pautados na realidade.

## 8. Conclusão

Este trabalho demonstrou que o uso de variáveis comportamentais no formato *xAPI* melhora a predição do desempenho acadêmico em AVAs. A metodologia desenvolvida serve como ferramenta para auxiliar os professores a identificarem precocemente alunos com risco de baixo desempenho ou evasão, bem como prever aqueles com probabilidade de sucesso, com base nas taxas de participação.

Embora o *dataset* utilizado apresente limitações, como a anonimização e o alto volume de inscritos inativos, ele cumpriu o propósito da pesquisa, especialmente diante da escassez de bases educacionais públicas estruturadas em *xAPI*. Em trabalhos futuros, a aplicação da metodologia em conjuntos de dados maiores e com menos ruído permitirá o treinamento de modelos ainda mais robustos.

Conclui-se, portanto, que a pesquisa respondeu à sua pergunta inicial: a conversão de registros para *xAPI* e o uso de métricas de engajamento superaram a abordagem de dados agregados tradicionais, extraíndo perfis comportamentais fundamentais para a análise preditiva educacional.

## Referências

BISWAS, P.; GHOSH, S. K. A novel approach to define performance metrics for students' and teachers' evaluation. *Electronic Journal of e-Learning*, v. 5, n. 2, p. 87–102, 2007.

KIZILCEC, R. F.; PIECH, C.; SCHNEIDER, E. Deconstructing disengagement: analyzing learner subpopulations in massive open online courses. In: *Proceedings of the third international conference on learning analytics and knowledge*. [S.l.: s.n.], 2013. p. 170–179.

LEITÃO, G. de S. *Uma Plataforma de Suporte ao Docente no Contexto da Educação Digital*. 77 p. Dissertação (Mestrado), Manaus, AM., mar. 2017. Disponível em: [⟨https://tede.ufam.edu.br/handle/tede/5889⟩](https://tede.ufam.edu.br/handle/tede/5889).

LI, T. et al. Relationship between learning engagement metrics and learning outcomes in online engineering course. In: IEEE. *2021 IEEE Frontiers in Education Conference (FIE)*. [S.l.], 2021. p. 1–5.

Moodle Pty Ltd. *Learn Moodle Anonymised Database: Teaching with Moodle August 2016*. 2016. Dataset. Depositado por Elizabeth Dalton em 15 fev. 2017. Disponível via Internet Archive: [⟨https://web.archive.org/web/20210420235203/http://research.moodle.org/158/3/anonymiseddatasetreadme.pdf⟩](https://web.archive.org/web/20210420235203/http://research.moodle.org/158/3/anonymiseddatasetreadme.pdf). Disponível em: [⟨http://research.moodle.org/id/eprint/158⟩](http://research.moodle.org/id/eprint/158).

PESCE, D. *moodle-logstore\_xapi*. [S.l.]: GitHub, 2026. [⟨https://github.com/davidpesce/moodle-logstore\\_xapi⟩](https://github.com/davidpesce/moodle-logstore_xapi). Acessado em: 11 jun. 2026.

ZHENG, S. et al. Understanding student motivation, behaviors and perceptions in moocs. In: *Proceedings of the 18th ACM Conference on Computer Supported Cooperative Work & Social Computing*. New York, NY, USA: Association for Computing Machinery, 2015. (CSCW '15), p. 1882–1895. ISBN 9781450329224. Disponível em: [⟨https://doi.org/10.1145/2675133.2675217⟩](https://doi.org/10.1145/2675133.2675217).

GARCIA, Danilo Balman; WANNER, Rafael Machado. Desenvolvimento de software para geração de métricas de desempenho e engajamento em avas via XAPI. 2025. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) ; Universidade Tecnológica Federal do Paraná, Campo Mourão, 2025.

## **9. Declaração sobre uso de Inteligência Artificial**

Foi utilizada a ferramenta Gemini 3.1 Pro para auxiliar no desenvolvimento e na otimização dos códigos-fonte (scripts) responsáveis pela análise e pelo tratamento dos *statements* empregados nesta pesquisa. Além disso, a inteligência artificial atuou como suporte para a revisão ortográfica, gramatical e para o aprimoramento da fluidez textual de trechos deste artigo. Em estrito atendimento ao Código de Conduta para Autores da Sociedade Brasileira de Computação (SBC), os autores assumem integral responsabilidade pela originalidade, veracidade e integridade de todo o conteúdo apresentado neste trabalho.